



DIPLOMADO

Introducción Analítica a la Ciencia de Datos

Predicción de Sobrecostos en Seguros Médicos

PROFESORES

Jorge Ignacio González Cázares
Alan Riva Palacio Cohen

ALUMNOS

Aguilera Yáñez Mariana
Alvarado Arce Axel Eduardo
Canseco Galván Tanivet Leonor
García Soto Kevin
Hernández Mareles Francisco Javier
Rendón Cardoso Karla
Suárez Urbano David Hiram

Estimación de Costos Médicos con Seguros de Salud

1,338 registros

Tamaño del dataset

6 variables

Predictores demográficos y de estilo de vida

7 modelos

Algoritmos evaluados y comparados

skewness = 1.52

Asimetría en variable objetivo

CONTEXTO Y MOTIVACIÓN

En la actualidad, los costos asociados a la atención médica representan una de las principales preocupaciones tanto para las compañías aseguradoras como para los propios beneficiarios. La capacidad de anticipar de manera precisa el gasto médico anual de un asegurado permite a las aseguradoras establecer primas más justas y sostenibles, además de identificar de forma temprana los perfiles de riesgo asociados a sobrecostos en la atención médica.

El proyecto tiene como objetivo estimar los cargos médicos anuales facturados por el seguro de salud, a partir de las características demográficas del beneficiario y de hábitos relacionados con su estilo de vida, en particular el consumo de tabaco. Este último factor resulta de especial interés, ya que diversos estudios han evidenciado una fuerte relación entre el tabaquismo y un incremento considerable en los gastos médicos.

DATASET

Variable	Descripción
age	Edad del beneficiario
sex	Sexo (male / female)
bmi	Índice de masa corporal
children	Número de hijos cubiertos
smoker	Consumo de tabaco (yes / no)
region	Región de residencia (EE. UU.)
charges	Cargos médicos anuales (USD)

Para este análisis se utilizó el conjunto de datos *Medical Cost Personal Datasets*, disponible en Kaggle, el cual contiene información real de beneficiarios junto con los cargos facturados por su seguro médico. La variable objetivo (**charges**) presenta una asimetría positiva significativa ($skewness = 1.52$), lo que motivó la aplicación de una transformación logarítmica en algunos modelos.

MODELOS A EVALUAR

Familia	Modelo	Característica principal
Regresión Regularizada	Ridge / Lasso	Control de complejidad y mitigación de sobreajuste mediante penalización L_2 / L_1
Métodos de Ensamble	Random Forest	Captura relaciones no lineales mediante árboles de decisión en paralelo
Métodos de Ensamble	AdaBoost	Boosting secuencial que pondera instancias mal clasificadas
Métodos de Ensamble	XGBoost	Boosting con regularización, alta velocidad y manejo de valores atípicos
Redes Neuronales	MLP / ANN	Aproximación universal de funciones; captura patrones complejos multicapa
Clasificación Complementaria	Regresión Logística	Identifica beneficiarios con alta probabilidad de generar sobrecostos

ENFOQUE METODOLÓGICO

Esta comparación de enfoques permitirá determinar la técnica que ofrezca el mejor balance entre precisión, interpretabilidad y capacidad de generalización para la predicción de costos en seguros médicos. Se implementarán técnicas de validación cruzada, optimización de hiperparámetros y transformaciones de la variable objetivo con el propósito de construir modelos robustos y de alto desempeño. Los resultados se evaluarán mediante métricas estándar de regresión (RMSE, MAE, R^2) y se compararán de forma sistemática entre todos los algoritmos.

Exploración y Preprocesamiento

1,337 obs.

Tras eliminar duplicado

0 faltantes

Valores nulos en dataset

skew 1.52

Asimetría original de charges

skew -0.09

Tras transformación log

OBJETIVO

El objetivo de esta etapa fue evaluar la calidad y consistencia de la información disponible, así como preparar el conjunto de datos para el desarrollo de modelos predictivos de costos médicos. Para ello, se realizó un análisis exploratorio orientado a identificar patrones, relaciones entre variables y posibles problemas de calidad. Posteriormente, se implementó un proceso de preprocesamiento que incluyó la eliminación de registros duplicados, la transformación logarítmica de la variable objetivo, la codificación de variables categóricas, la partición de los datos en conjuntos de entrenamiento y prueba, y la estandarización de las variables numéricas.

1.1 EXPLORACION DE DATOS

Variable	Tipo	Observación
age	Númérica	Rango: 18-64 años
sex	Categórica	675 M / 662 F
bmi	Númérica	Media: 30.66
children	Discreta	Rango: 0-5
smoker	Binaria	1,063 no / 274 sí
region	Categórica	4 regiones balanceadas
charges	Númérica	Media: \$13,279


Fuente: Medical Cost Personal Dataset (1,338 registros originales).

El dataset no presentó valores faltantes en ninguna de sus variables. Únicamente se detectó **un registro duplicado** (asegurado de 19 años, sexo masculino, BMI = 30.59, región northwest, charges = \$1,639.56), el cual fue eliminado, resultando en **1,337** observaciones únicas para el análisis.

Por otro lado, las variables **sex** y **region** presentaron distribuciones equilibradas entre categóricas. En contraste, **smoker** mostró un claro predominio de no fumadores (79.5%), lo que anticipa su alto poder discriminativo sobre los costos médicos.

1.2 ANALISIS DE VARIABLES

Variable	Media	D. Est.	Máx.	r(charges)
age	39.22	14.04	64.00	0.30
bmi	30.66	6.10	53.13	0.20
children	1.10	1.21	5.00	0.07
charges	\$13,279	\$12,110	\$63,770	1.00



El análisis exploratorio mostró que **age** y **bmi** mantienen una relación positiva con los costos médicos, mientras que **children** presenta una contribución limitada. Finalmente, **smoker** evidenció diferencias sustanciales entre ambos grupos, anticipándose como la variable con mayor capacidad explicativa.

La variable **charges** tiene una asimetría positiva (*skewness* = 1.52), por lo que se aplicó una transformación logarítmica durante el preprocesamiento. Tras aplicar $\log(\text{charges})$, la asimetría se redujo a -0.09, obteniendo una distribución considerablemente más simétrica y adecuada para el entrenamiento del modelo.

1.3 PREPROCESAMIENTO

Paso	Resultado
Eliminación de duplicado	1,338 → 1,337 registros.
Transformación $\log(\text{charges})$	skewness: 1.52 → -0.09
One-Hot Encoding (OHE)	3 categóricas → 5 dummies
División train/test (80/20)	1,069 train / 268 test
StandardScaler (solo train)	Media $\approx$ 0, D. Est. $\approx$ 1

El One-Hot Encoding se aplicó con `drop_first=True` sobre **sex**, **smoker** y **region**, generando 5 variables dummy y eliminando las categorías de referencia (**female**, **no**, **northeast**) para evitar multicolinealidad. Por lo que, el dataset final quedó con **8 variables predictoras**.

El escalamiento con **StandardScaler** se ajustó exclusivamente con los datos de entrenamiento y se aplicó al conjunto de prueba, evitando *data leakage* garantizando una evaluación imparcial del modelo.

CONCLUSIÓN

Los resultados indican que la base de datos posee una calidad adecuada para el modelado y que los principales determinantes del gasto médico son el tabaquismo, la edad y el BMI. Además, la marcada asimetría y la presencia de valores extremos en la variable objetivo justifican la evaluación de transformaciones y modelos robustos durante las etapas posteriores del proyecto

Clasificación de Sobrecostos con Regresión Logística

Accuracy = 90.67%

Exactitud global del modelo

F1 Score = 90.77%

Equilibrio precisión-recall

Prob. = 96.79%

Caso hipotético fumador, 23 años

80 / 20

Partición entrenamiento / prueba


OBJETIVO Y PREPROCESAMIENTO

La Regresión Logística se utilizó para clasificar individuos según la presencia o ausencia de sobrecostos médicos, mediante una variable objetivo binaria (*sobrecosto*) construida a partir de los gastos registrados. Los datos se dividieron en entrenamiento (80%) y prueba (20%) con estratificación para mantener la proporción de clases. Las variables predictoras fueron estandarizadas para mejorar el desempeño del algoritmo.


METRICAS DE DESEMPEÑO Y MATRIZ DE CONFUSION

Métrica	Valor
Accuracy	90.67%
F1 Score	90.77%

La mayoría de las observaciones fueron clasificadas correctamente. Los errores de clasificación fueron relativamente bajos, lo que respalda la solidez del modelo en tareas de clasificación binaria y evidencia un equilibrio adecuado entre precisión y detección de casos positivos.



IMPORTANCIA DE VARIABLES



Variable	Influencia
smoker_yes	Principal
age	Alta
bmi	Moderada
sex / region_*	Baja

smoker_yes presentó el coeficiente más alto, incrementando considerablemente la probabilidad de pertenecer al grupo de sobrecosto. La edad también mostró influencia importante, mientras que el sexo y la región geográfica presentaron efectos menores.

CONCLUSION

La Regresión Logística demostró ser un modelo eficaz para la clasificación de sobrecostos médicos (Accuracy = 90.67%, F1 = 90.77%), logrando un equilibrio adecuado entre precisión y detección de casos positivos. La demostración con el individuo hipotético confirmó el correcto funcionamiento del modelo, asignando una probabilidad de sobrecosto del 96.79% a un fumador joven, evidenciando que el tabaquismo constituye el principal factor de riesgo para la generación de gastos médicos elevados.

Estimación de Costos Médicos con Regresión Ridge

$R^2 = 80.50\%$

Variabilidad explicada por el modelo

$MAE = \$4,202.58$

Error absoluto medio

$\alpha = 10$

Penalización L_2 óptima

$RMSE = \$5,985.73$

Rafz del error cuadrático medio


OBJETIVO Y PREPROCESAMIENTO

La Regresión Ridge fue utilizada para predecir los gastos médicos individuales incorporando una penalización L_2 sobre los coeficientes, con el objetivo de reducir el sobreajuste y obtener estimaciones más estables. Los datos fueron sometidos a limpieza y estandarización mediante un *Pipeline* de Scikit-Learn. El nivel óptimo de regularización ($\alpha = 10$) se determinó mediante búsqueda de hiperparámetros con validación cruzada.


METRICAS DE DESEMPEÑO Y COMPORTAMIENTO PREDICTIVO

Métrica	Valor (USD)
R^2	0.8050
MAE	\$4,202.58
MSE	\$35,828,958.09
RMSE	\$5,985.73

El modelo explica el 80.5% de la variabilidad de los gastos médicos. Las desviaciones más pronunciadas se concentran en individuos con costos particularmente elevados.



IMPORTANCIA DE VARIABLES



Variable	Influencia
smoker_yes	Principal
age	Alta
bmi	Moderada
sex / region_*	Baja

El tabaquismo constituye el principal factor asociado al incremento de costos, coincidiendo con la evidencia médica que lo relaciona con mayor incidencia de enfermedades y tratamientos de alto costo. La edad y el BMI completan los factores de mayor impacto, mientras que región y sexo muestran efectos menores.

CONCLUSIÓN DEL MODELO

La Regresión Ridge demostró ser una herramienta eficaz para la predicción de gastos médicos individuales ($R^2 = 0.8050$), capturando gran parte de la variabilidad presente en los costos a partir de información demográfica y de salud básica. La penalización L_2 permitió obtener coeficientes estables, confirmando que el tabaquismo, la edad y el índice de masa corporal son los principales determinantes del gasto médico.

Estimación de Costos Médicos con Regresión Lasso

$R^2 = 80.45\%$

Variabilidad explicada por el modelo

$MAE = \$4,188.02$

Error absoluto medio

$\lambda = 55$

Penalización L_1 óptima (5-fold CV)

2 variables

Eliminadas automáticamente por Lasso

OBJETIVO Y PREPROCESAMIENTO

Lasso incorpora penalización L_1 que reduce coeficientes de variables poco informativas exactamente a cero, simplificando el modelo sin sacrificar capacidad predictiva. Se construyó un *Pipeline* con estandarización y el parámetro óptimo $\lambda = 55$ se obtuvo mediante validación cruzada de 5 *folds*.

RESULTADOS Y EFECTO DE LA REGULARIZACION


Métrica	Valor
R^2	0.8045
MAE	\$4,188.02
RMSE	\$5,993.89
λ opt.	55

λ	R^2	Eliminadas
0	0.8069	Ninguna
25	0.8059	Ninguna
45	0.8050	sex_male
55	0.8045	sex_m., reg_nw
100	0.8024	sex_m., reg_nw


El R^2 cae apenas 0.003 al pasar de $\lambda = 0$ a $\lambda = 55$, mientras el modelo elimina automáticamente **sex_male** y **region_northwest**, demostrando la ventaja clave de Lasso: **simplificar sin perder precisión**.

IMPORTANCIA DE VARIABLES

Variable	Coef.
smoker_yes	9,173.01
age	3,431.83
bmi	1,841.91
children	586.43
Las demas variables	< 0



VALIDACIÓN GRÁFICA (REAL VS. PREDICHO)



La mayoría de los puntos se concentra cerca de la diagonal ideal, confirmando un buen ajuste general del modelo. Sin embargo, para valores extremadamente altos, algunos puntos quedan por debajo de la diagonal, lo que indica que Lasso tiende a **subestimar ciertos gastos médicos extraordinarios**. Esta limitación es esperada en modelos lineales cuando existen relaciones complejas o valores atípicos, y justifica la evaluación de métodos de ensamble en etapas posteriores.

CONCLUSION DEL MODELO

Lasso demostró ser una alternativa sólida e interpretable ($R^2 = 0.8045$, $RMSE = \$5,993.89$), con la ventaja de eliminar automáticamente variables irrelevantes mediante penalización L_1 . El tabaquismo, la edad y el BMI son los principales determinantes del gasto médico; el sexo y ciertas regiones geográficas tienen impacto limitado.

Estimación de Costos Médicos con Random Forest

$R^2 = 89.19\%$

Mejor ajuste global (RF Optimizado)

MAE = \$2,544.68

Menor error promedio (RF Optimizado)

smoker_yes = 67.20%

Importancia variable dominante

+1.22% R^2

Mejora tras optimización

PROCEDIMIENTO EJECUTADO

- Entrenamiento de un modelo base (`RandomForestRegressor`, 100 estimadores, parámetros por defecto) sobre `charges`.
- Evaluación en escala original (USD) mediante las métricas MAE, RMSE y R^2 .
- Cálculo de la importancia de variables (`feature_importances_`) para identificar los predictores más relevantes.
- Optimización de hiperparámetros mediante `RandomizedSearchCV` (20 combinaciones, `cv=5`, métrica `r2`).
- Reentrenamiento con los mejores hiperparámetros y evaluación comparativa contra el modelo base.

COMPARATIVA DE RESULTADOS

Modelo	RMSE	MAE	R^2
Base	\$4,702.45	\$2,637.99	0.8797
Optimizado	\$4,457.61	\$2,544.68	0.8919

Hiperparámetros óptimos encontrados:

`n_estimators=100`, `max_depth=20`, `min_samples_split=10`,
`min_samples_leaf=2`, `max_features=0.5`, `bootstrap=True`.

Mejor R^2 en validación cruzada: 0.8390.

El modelo optimizado supera al modelo base, explicando el 89.2% de la variabilidad en los cargos médicos con un error promedio de \$2,544.68.


IMPORTANCIA DE VARIABLES

Variable	Importancia relativa
smoker_yes	0.6720
bmi	0.1600
age	0.1332
children	0.0181
Las demas variables	<

La condición de fumador (`smoker_yes`) concentra más del 67% de la capacidad predictiva del modelo. Le siguen el índice de masa corporal (`bmi`) con un 16% y la edad (`age`) con un 13.3%, sumando en conjunto más del 96% de la importancia total.

Variables como sexo y región resultan prácticamente irrelevantes, con importancias individuales menores al 0.5%.

COMPORTAMIENTO PREDICTIVO DEL MODELO



La dispersión de predicciones se ajusta de forma cercana a la diagonal ideal en costos bajos y medios (<\$30,000), donde se concentra la mayoría de los registros.

En costos elevados (>\$40,000) —principalmente fumadores con IMC alto— el modelo tiende a subestimar ligeramente, comportamiento esperado al tratarse de un segmento minoritario en el conjunto de entrenamiento.

CONCLUSION DEL MODELO

El modelo Random Forest optimizado logra el mejor desempeño ($R^2 = 0.8919$, MAE = \$2,544.68), superando al modelo base en todas las métricas. La búsqueda de hiperparámetros confirmó que permitir mayor profundidad máxima (`max_depth=20`) junto con una mayor restricción en la división mínima (`min_samples_split=10`) reduce el sobreajuste y mejora la generalización. La variable `smoker_yes` domina la predicción con más del 67% de importancia, seguida por `bmi` y `age` con un 29% combinado.

Estimación de Costos Médicos con AdaBoost

$R^2 = 89.78\%$

Variabilidad explicada por el modelo

$MAE = \$2,696.42$

Error absoluto medio

smoker $\approx 70\%$

Importancia variable dominante

$RMSE = \$4,334.14$

Rafz del error cuadrático medio

OBJETIVO Y CONFIGURACION OPTIMA

Parámetro	Valor óptimo
Profundidad máxima	4 niveles
Número de iteraciones	50
Tasa de aprendizaje	0.01
Validación cruzada	5 pliegues (GridSearchCV)


Como primera aproximación avanzada se implementó un ensamble AdaBoost. Para garantizar robustez matemática y evitar el sobreajuste, se aplicó validación cruzada de 5 pliegues mediante *GridSearchCV*, seleccionando la arquitectura óptima con estimadores base de profundidad 4, 50 iteraciones y tasa de aprendizaje de 0.01.

RESULTADOS E IMPORTANCIA DE VARIABLES

Métrica	Valor (USD)
R^2	0.8978
MAE	\$2,696.42
RMSE	\$4,334.14


Variable	Importancia
smoker_yes	$\approx 70\%$
bmi	Alta
age	Moderada
sex / region_*	Marginal

Curva de Aprendizaje: Evolución de la Corrección de Errores (AdaBoost)



La Curva de Aprendizaje confirma la eficacia de la corrección secuencial: caída drástica y posterior estabilización del error sin memorizar los datos de entrenamiento. El tabaquismo concentra $\approx 70\%$ de la capacidad predictiva total, seguido del Índice de Masa Corporal y la edad; las variables sociodemográficas mostraron impacto marginal.

VALIDACION GRAFICA (REAL VS. PREDICHO)



La gran mayoría de los pacientes se agrupa estrechamente sobre la línea de predicción perfecta en costos bajos y medios. Sin embargo, los casos con gastos superiores a \$30,000 muestran mayor dispersión, confirmando que estimar el costo residual de emergencias médicas extremas sigue siendo el principal desafío del modelo ante valores atípicos extremos.

CONCLUSION

AdaBoost controló la alta varianza de los árboles individuales y capturó la dinámica principal del gasto médico ($R^2 = 0.8978$), confirmando al tabaquismo como factor determinante. La dispersión observada en escenarios catastróficos sugiere que el ruido residual exige herramientas más sofisticadas, motivando la evaluación de XGBoost y Redes Neuronales en etapas posteriores.

Estimación de Costos Médicos con XGBoost

$R^2 = 90.1\%$

Mejor ajuste global (XGBoost Normal)

MAE = \$2,094

Menor error promedio (XGBoost Log)

smoker = 75%

Importancia variable dominante

-16% MAE

Ganancia por transformación log

OBJETIVO Y DATOS

El objetivo fue predecir los costos médicos anuales (**charges**) a partir de variables demográficas y de comportamiento mediante XGBoost, algoritmo seleccionado por su capacidad para capturar relaciones no lineales e interacciones complejas. Durante la exploración se identificó una marcada asimetría positiva en la variable objetivo (*skewness* = 1.52), por lo que se aplicó una transformación logarítmica que la redujo a -0.09, obteniendo una distribución más simétrica para el entrenamiento.

MODELOS EVALUADOS

Modelo	Target	d_max	n_est	lr	sub	col	α	λ
XGBoost Normal	charges	2	300	0.03	0.8	0.8	0	5
XGBoost Logarítmico	log(charges)	3	200	0.03	0.8	0.8	0	1

COMPARATIVA DE RESULTADOS

Modelo	R^2	MAE	MSE	RMSE
XGBoost Normal	0.9014	\$2,498	\$18,113,225	\$4,256
XGBoost Logarítmico	0.8932	\$2,095	\$19,630,042	\$4,431

El modelo XGBoost sobre la variable original obtuvo el mejor ajuste global ($R^2 = 0.9014$, MAE = \$2,498, RMSE = \$4,256), mientras que la versión logarítmica redujo el error promedio (MAE = \$2,095) a costa de menor poder explicativo ($R^2 = 0.8932$) y mayor RMSE (\$4,431).


Contrario a lo esperado, la transformación logarítmica, aunque corrigió la asimetría del de la variable objetivo, atenuó la sensibilidad del modelo ante valores extremos, precisamente los de mayor impacto económico para una aseguradora.

IMPORTANCIA DE VARIABLES

Variable	Normal	Log
smoker_yes	75.45%	69.65%
bmi	12.15%	2.62%
age	8.73%	16.98%
children	1.87%	3.51%
sex_male	0.73%	2.88%
region_*	1.07%	4.36%

La variable smoker fue el factor más influyente, concentrando entre el 70% y 75% de la importancia total del modelo, lo cual coincide con la evidencia actuarial que identifica al tabaquismo como principal determinante del gasto en salud. La transformación logarítmica redujo la importancia relativa de BMI e incrementó la contribución de la edad, sugiriendo que al reducir la asimetría el modelo capturó con mayor claridad el efecto gradual de esta variable sobre los costos.

COMPORTAMIENTO PREDICTIVO DE LOS MODELOS



Se observa que, ambos modelos siguieron la tendencia general de los costos en el conjunto de prueba. En el segmento bajo y medio (observaciones 0-180), las predicciones se mantuvieron cercanas a los valores reales sin sesgos evidentes. Sin embargo, a partir de la observación 180 las desviaciones se volvieron más pronunciadas, y en el extremo derecho ambos modelos subestimaron significativamente el caso de costo superior a \$60,000, evidenciando la limitación estructural ante valores extremos.

CONCLUSION DEL MODELO

XGBoost demostró ser una herramienta efectiva para la predicción de costos médicos, explicando aproximadamente el 90% de su variabilidad. El modelo sobre la variable original presentó mejor desempeño global y mayor capacidad para capturar casos de alto costo (RMSE = \$4,256 vs. \$4,431), mientras que la versión logarítmica redujo el error promedio a costa de menor ajuste general. El tabaquismo se identificó como el principal determinante del gasto médico.

Estimación de Costos Médicos con Red Neuronal

$R^2 = 89\%$

Mejor modelo (Red 3)

MAE = 2,783

Error absoluto medio del modelo final

4 redes

Iteraciones evaluadas progresivamente

Dropout 15%

Regularización del mejor modelo

OBJETIVO Y CONFIGURACIÓN BASE

Parámetro	Configuración
Arquitectura base	1 capa oculta, 16 neuronas ReLU
Optimizador	Adam
Función de pérdida	MSE (base) → Huber (Red 4)
Épocas / lote	100 / 32 observaciones
Validación	20% datos de entrenamiento
Regularización	Dropout 15% + Early Stopping


La red base (16 neuronas, 1 capa oculta) produjo un $R^2 = -1.04$, evidenciando un **escalado inconsistente**: las variables de entrada en rango reducido versus **charges** con magnitudes mucho mayores dificultaron el aprendizaje. Esto motivó tres iteraciones sucesivas de mejora, siendo el **mejor modelo la Red 3**, con optimización de arquitectura y regularización.

COMPARATIVA DE ITERACIONES

Red	Mejora incorporada	MAE	RMSE	R^2
Red 1	Configuración base	14,001	19,371	-1.04
Red 2	Rescalamiento de charges	2,940	4,666	0.88
Red 3	Arquitectura ampliada + Dropout + Early Stopping	2,783	4,453	0.89
Red 4	Pérdida Huber	2,609	4,599	0.88

El rescalamiento de la variable objetivo (Red 2) representó el mayor salto de desempeño (R^2 pasó de -1.04 a 0.88). La Red 3 alcanzó el mejor equilibrio con mayor capacidad arquitectónica y regularización. La pérdida Huber (Red 4) redujo el MAE pero no mejoró el R^2 ni el RMSE, por lo que **la Red 3 es el modelo final seleccionado**.

EVOLUCION DEL DESEMPEÑO



La gráfica muestra la evolución del desempeño a través de las cuatro redes. Se aprecia una mejora sustancial entre Red 1 y Red 2 producto del rescalamiento, seguida de ganancias progresivas en las iteraciones siguientes. La Red 3 consolida el mejor ajuste ($R^2 = 0.89$, RMSE = 4,453), mientras que la Red 4 con pérdida Huber no logra superar este resultado en términos globales.

CONCLUSION DEL MODELO

Las iteraciones muestran una evolución clara: desde un inicio deficiente ($R^2 = -1.04$) hasta alcanzar métricas sólidas con la incorporación de rescalamiento, optimización arquitectónica y regularización. El mejor modelo obtenido es la **Red 3** ($R^2 = 0.89$, RMSE = 4,453, MAE = 2,783), logrando un excelente equilibrio entre precisión y capacidad de generalización para la predicción de costos médicos.

Comparación de Modelos

$R^2 = 90.14\%$

Mejor modelo global (XGBoost)

MAE = \$2,497.91

Menor error promedio (XGBoost)


7 modelos

Algoritmos evaluados y comparados

+10 p.p.

Ganancia vs. modelos lineales


MODELOS LINEALES COMO LÍNEA BASE



Las regresiones Lineal, Lasso ($\lambda = 55$) y Ridge ($\lambda = 10$) constituyeron una línea base sólida con $R^2 \approx 80\%$. La regularización aportó estabilidad, pero las mejoras frente a la regresión clásica fueron limitadas. Esto sugiere que la relación entre las variables explicativas y los costos médicos contiene **componentes no lineales** que estos modelos no logran capturar completamente.

COMPARATIVA GENERAL DE MODELOS

Modelo	MAE	RMSE	R^2
Regresión Lineal	—	—	≈ 0.80
Lasso	\$4,188.02	\$5,993.89	0.8045
Ridge	\$4,202.58	\$5,985.73	0.8050
AdaBoost	\$2,696.42	\$4,334.14	0.8978
Random Forest	\$1,950.84	\$4,234.50	0.8919
Red Neuronal	\$2,783.00	\$4,453.00	0.8921
XGBoost	\$2,497.91	\$4,255.96	0.9014



Random Forest ($R^2 = 0.8919$) y la Red Neuronal ($R^2 = 0.8921$) alcanzaron un desempeño competitivo y similar, aunque la red requiere mayor complejidad computacional sin traducirse en mejoras significativas. **XGBoost** se posicionó como el mejor modelo global, superando en las tres métricas a todos los algoritmos evaluados.

CONCLUSION DE LA COMPARACION

XGBoost explicó aproximadamente el **90%** de la variabilidad de los costos médicos con los menores errores de predicción entre todos los modelos evaluados. Un hallazgo relevante es que este desempeño se alcanzó sin variables clínicas como diagnósticos, hipertensión o enfermedades crónicas, demostrando el potencial del aprendizaje automático para generar estimaciones precisas con información básica. La incorporación de variables clínicas adicionales representa una oportunidad clara para fortalecer el modelo en escenarios reales de toma de decisiones.

Conclusiones Generales

$R^2 = 90.14\%$

XGBoost — mejor modelo global

OR = 21.90

Odds Ratio de `smoker_yes`

0 vars. clínicas

Desempeño con datos básicos

MODELOS LINEALES VS. METODOS DE ENSAMBLE

Modelo	MAE	RMSE	R^2
Lasso ($\lambda=55$)	\$4,188	\$5,994	0.8045
Ridge ($\lambda=10$)	\$4,203	\$5,986	0.8050
AdaBoost	\$4,334	\$2,696	0.8978
Red Neuronal (Red 3)	\$2,783	\$4,453	0.8921
Random Forest	\$1,951	\$4,235	0.8919
XGBoost	\$2,498	\$4,256	0.9014

Los modelos lineales alcanzaron $R^2 \approx 80\%$, confirmando la presencia de **componentes no lineales** en la relación entre variables y costos. La regularización de Lasso eliminó automáticamente `sex_male` y `region_northwest`, confirmando que estas variables carecen de poder discriminativo sustancial.

XGBoost superó a todos los algoritmos en las tres métricas gracias a su *boosting* secuencial con corrección de residuos.

Random Forest alcanzó desempeño competitivo ($R^2 = 0.8919$) con menor MAE que XGBoost en algunas configuraciones, aunque con mayor sensibilidad a errores extremos.

RED NEURONAL Y EFECTO DE LA TRANSFORMACION LOGARITMICA

La Red Neuronal (Red 3, $R^2 = 0.89$) alcanzó métricas comparables a Random Forest, pero requirió múltiples iteraciones correctivas —rescalamiento de `charges`, ampliación arquitectónica y Dropout 15% + Early Stopping— para superar problemas de escala que inicialmente generaban $R^2 = -1.04$. Esto evidencia una **mayor sensibilidad al preprocesamiento** respecto a los modelos basados en árboles, invariantes a la escala.

La transformación logarítmica corrigió la asimetría positiva de `charges` (*skewness*: $1.52 \rightarrow -0.09$) y redujo el MAE en XGBoost logarítmico a \$2,095 (−16%), pero a costa de menor R^2 (0.8932) y mayor RMSE (\$4,431).

En un contexto actuarial donde los **casos de alto costo son los más relevantes**, el modelo sobre escala original resulta preferible.

IMPORTANCIA DE VARIABLES: HALLAZGO TRANSVERSAL

Variable	Ensamble	Reg. Log.
<code>smoker_yes</code>	67%–75%	OR = 21.90
<code>age</code>	12%–38%	OR = 8.97
<code>bmi</code>	10%–19%	—
<code>children</code>	< 5%	—
<code>sex / region_*</code>	prácticamente irrelevantes	

`smoker_yes` dominó consistentemente la capacidad predictiva en **todos** los algoritmos evaluados (67%–75%), seguida de `bmi` y `age` con contribuciones combinadas del 25%–30%.

Este patrón, robusto a través de modelos de naturaleza muy distinta, refuerza la validez estadística del hallazgo y su coherencia con la evidencia médica y actuarial. La Regresión Logística corroboró este resultado: un fumador tiene **casi 22 veces** más probabilidad de incurrir en sobrecostos médicos.

CONCLUSION FINAL

Hallazgo	Evidencia
Problema no lineal	Brecha de +10 p.p. ensamble vs. lineal
Variable dominante	<code>smoker_yes</code> en todos los modelos
Mejor modelo global	XGBoost ($R^2 = 0.9014$)
Escala original preferible	Mayor precisión en casos extremos
Margen de mejora	Incorporar variables clínicas

A lo largo del proyecto se demostró que es posible predecir costos médicos con alta precisión ($R^2 \approx 90\%$) utilizando únicamente variables demográficas y de comportamiento básico.

Los métodos de ensamble, liderados por XGBoost, superaron consistentemente a los modelos lineales al capturar relaciones no lineales que éstos no logran modelar.

El tabaquismo se confirmó como el principal determinante del gasto médico en todos los algoritmos evaluados, resultado coherente con la evidencia médica y actuarial.

Una mejora que sería buena incorporación al resto de variables, podrían ser variables clínicas adicionales las cuales representarían un paso natural para fortalecer estos modelos en aplicaciones reales.